DATAINSIGHT

Intelligent Dataset Analyzer

Exemple — analyse du jeu « ventes »

ventes_mixte.csv

CSV (valeurs séparées) — 1 000 lignes × 12 colonnes

97,9/100	4,5 %	0
Score qualité (heuristique)	Valeurs manquantes	Doublons

Rapport généré le 11/11/2026 à 00:59
DATAINSIGHT v1.0.0 — analyse 100 % locale

Sommaire

Synthèse exécutive 3

1. Présentation du dataset 3

2. Caractéristiques générales 3

3. Description des variables 3

4. Statistiques descriptives 4

5. Analyse des valeurs manquantes 6

6. Audit de qualité 6

7. Analyse des corrélations 7

8. Visualisations principales 8

9. Interprétations statistiques 12

10. Recommandations 13

Synthèse exécutive

- Le jeu de données contient 1 000 observations et 12 variables (5 quantitative(s), 5 qualitative(s), 1 temporelle(s), 1 autre(s)).
- Taux global de valeurs manquantes : 4,5 % ; lignes complètes : 463 ; doublons : 0.
- Score de qualité (heuristique) : 97,9/100 (excellente) ; 3 problème(s) majeur(s) ou critique(s).
- 2 variable(s) quantitative(s) à distribution asymétrique : prix_unitaire, montant_total.
- 1 corrélation(s) forte(s) ; la plus marquée : prix_unitaire × montant_total (r = 0,870).
- Points d'attention prioritaires : valeurs atypiques potentielles (prix_unitaire) ; valeurs atypiques potentielles (montant_total) ; valeurs manquantes (commentaire).

1. Présentation du dataset

Ce rapport présente l'analyse automatique du fichier « ventes_mixte.csv » (CSV (valeurs séparées), 134.6 Ko) : structure, statistiques descriptives, qualité des données, relations entre variables et recommandations.

Aperçu des premières observations

id_commande	date_commande	produit	ville	latitude	longitude	quantite	prix_unitaire
CMD-100000	2023-03-07	Souris	Paris	48,8575	2,309	4	22,95
CMD-100001	2024-07-18	Souris	Marseille	43,2978	5,3691	4	26,82
CMD-100002	2024-04-22	Casque	Paris	48,8491	2,3318	5	72,3
CMD-100003	2023-11-17	Clavier	Lyon	45,7861	4,8377	5	43,97
CMD-100004	2023-11-13	Clavier	Marseille	43,2899	5,3482	4	42,89
CMD-100005	2024-09-18	Souris	Paris	48,8482	2,3607	2	25,33
CMD-100006	2023-03-04	Écran	Lyon	45,7836	4,8361	3	208,73
CMD-100007	2024-05-24	Souris	Lyon	45,7532	4,8637	3	24,46

(4 colonne(s) supplémentaire(s) non affichée(s).)

2. Caractéristiques générales

Caractéristique	Valeur
Fichier	ventes_mixte.csv
Format détecté	CSV (valeurs séparées)
Taille du fichier	134.6 Ko
Encodage	utf-8
Séparateur	virgule (,)
Feuille / table	—
Lignes	1 000
Colonnes	12
Cellules	12 000
Valeurs manquantes	537 (4,5 %)
Lignes dupliquées	0 (0,0 %)
Lignes complètes	463
Mémoire	0,15 Mo
Variables quantitatives	5
Variables qualitatives	5
Variables temporelles	1
Autres variables	1
Lecture partielle	non

3. Description des variables

Variable	Type détecté	Type statistique	Valeurs uniques	Valeurs manquantes	Justification
id_commande	texte	Identifiant	1000	0	Valeurs uniques sans espaces : identifiant probable.
date_commande	texte (date)	Date	541	0	Valeurs de date (sans heure). Format : %Y-%m-%d.
produit	texte	Catégorielle nominale	5	0	5 modalités distinctes.
ville	texte	Catégorielle nominale	5	0	5 modalités distinctes.
latitude	réel	Latitude	1000	0	Nom évocateur et valeurs dans [-90, 90].
longitude	réel	Longitude	1000	0	Nom évocateur et valeurs dans [-180, 180].
quantite	entier	Numérique discrète	5	0	Entiers avec 5 valeurs distinctes.
prix_unitaire	réel	Numérique continue	919	0	Nombres réels.
montant_total	réel	Numérique continue	993	0	Nombres réels.
remise_appliquee	booléen	Booléenne	2	0	Type booléen natif.
note_client	entier	Catégorielle ordinale	5	0	Échelle entière courte et nom évocateur (note, niveau…).
commentaire	texte	Catégorielle nominale	4	537	4 modalités distinctes.

4. Statistiques descriptives

Conventions : variance et écart-type d'échantillon (n − 1) ; quartiles par interpolation linéaire ; asymétrie et excès d'aplatissement corrigés du biais ; valeurs manquantes et infinies exclues.

Variables quantitatives

Indicateur	latitude	longitude	quantite	prix_unitaire	montant_total
Valides	1 000	1 000	1 000	1 000	1 000
Manquants	0	0	0	0	0
Moyenne	46,52	3,371	3,005	207,6244	623,2502
Médiane	45,7668	3,0527	3	48,69	176,395
Écart-type	2,8593	1,4691	1,3975	302,3414	1 030,3959
Minimum	43,2522	1,3971	1	19,47	19,47
Q1	43,5953	2,3361	2	27,4	87,1675
Q3	48,8684	4,8457	4	220,1	666,645
Maximum	50,684	5,4346	5	1 063,66	5 121,87
IQR	5,273	2,5096	2	192,7	579,4775
Coef. de variation	0,0615	0,4358	0,465	1,4562	1,6533
Asymétrie	0,2046	0,1623	-0,0244	1,7655	2,4457
Aplatissement (excès)	-1,58	-1,5281	-1,2737	1,4964	5,2709

Variables qualitatives

Variable	Valides	Manquants	Modalités	Modalité dominante	Effectif dominante	% dominante	Entropie normalisée	Ordonnée
produit	1000	0	5	Souris	286	28,6	0,9665	non
ville	1000	0	5	Paris	236	23,6	0,9975	non
remise_appliquee	1000	0	2	Faux	740	74	0,8267	non
note_client	1000	0	5	4	362	36,2	0,8869	oui
commentaire	463	537	4	Service client réactif, remboursement effectué sans difficu…	131	28,29	0,9979	non

Fréquences — produit

Modalité	Effectif	Fréquence	%
Souris	286	0,286	28,6
Clavier	253	0,253	25,3
Écran	200	0,2	20
Ordinateur	152	0,152	15,2
Casque	109	0,109	10,9

Fréquences — ville

Modalité	Effectif	Fréquence	%
Paris	236	0,236	23,6
Lyon	195	0,195	19,5
Marseille	191	0,191	19,1
Toulouse	191	0,191	19,1
Lille	187	0,187	18,7

Fréquences — remise_appliquee

Modalité	Effectif	Fréquence	%
Faux	740	0,74	74
Vrai	260	0,26	26

Fréquences — note_client

Modalité	Effectif	Fréquence	%	Effectif cumulé	% cumulé
1	54	0,054	5,4	54	5,4
2	95	0,095	9,5	149	14,9
3	194	0,194	19,4	343	34,3
4	362	0,362	36,2	705	70,5
5	295	0,295	29,5	1000	100

Fréquences — commentaire

Modalité	Effectif	Fréquence	%
Service client réactif, remboursement effectué sans difficu…	131	0,2829	28,29
Livraison rapide et produit conforme à la description, je r…	113	0,2441	24,41
Qualité décevante pour le prix, je ne commanderai probablem…	110	0,2376	23,76
Emballage abîmé mais le produit fonctionne correctement apr…	109	0,2354	23,54

Variables temporelles

Indicateur	date_commande
Effectif	1000
Valides	1000
Manquants	0
Date minimale	04/01/2023
Date maximale	30/12/2024
Étendue (jours)	726
Dates distinctes	541
Fréquence estimée	journalière
Écart médian (jours)	1
Ruptures détectées	134
Horodatages dupliqués	459
Dates futures	0
Dates < 1900	0

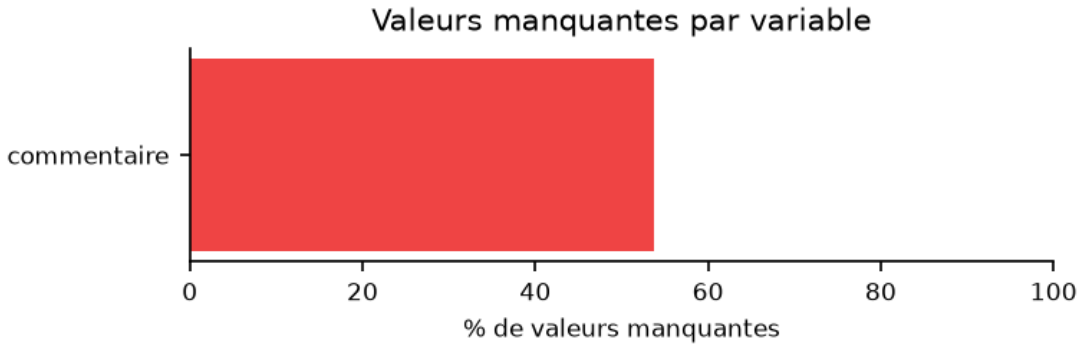
date_commande : 134 interruption(s) : écart supérieur à 1,5 × l'écart médian (1.00 j).

date_commande : 24.8 % des écarts s'éloignent de la fréquence journalière.

5. Analyse des valeurs manquantes

537 valeurs manquantes au total (4,5 % des cellules), réparties sur 1 variable(s).

Variable	Valeurs manquantes	% manquants	Valeurs renseignées
commentaire	537	53,7	463



6. Audit de qualité

Score global : 97,9/100 — appréciation : excellente.

Ce score est un indicateur heuristique destiné à prioriser les actions : moyenne pondérée de sous-scores (règles ci-dessous). Il ne constitue pas une mesure universelle de la qualité et dépend du contexte métier.

Composante	Score (/100)	Pondération (%)
Complétude	95,53	35
Unicité	100	20
Validité	100	20
Cohérence	100	15
Valeurs atypiques	94,56	10

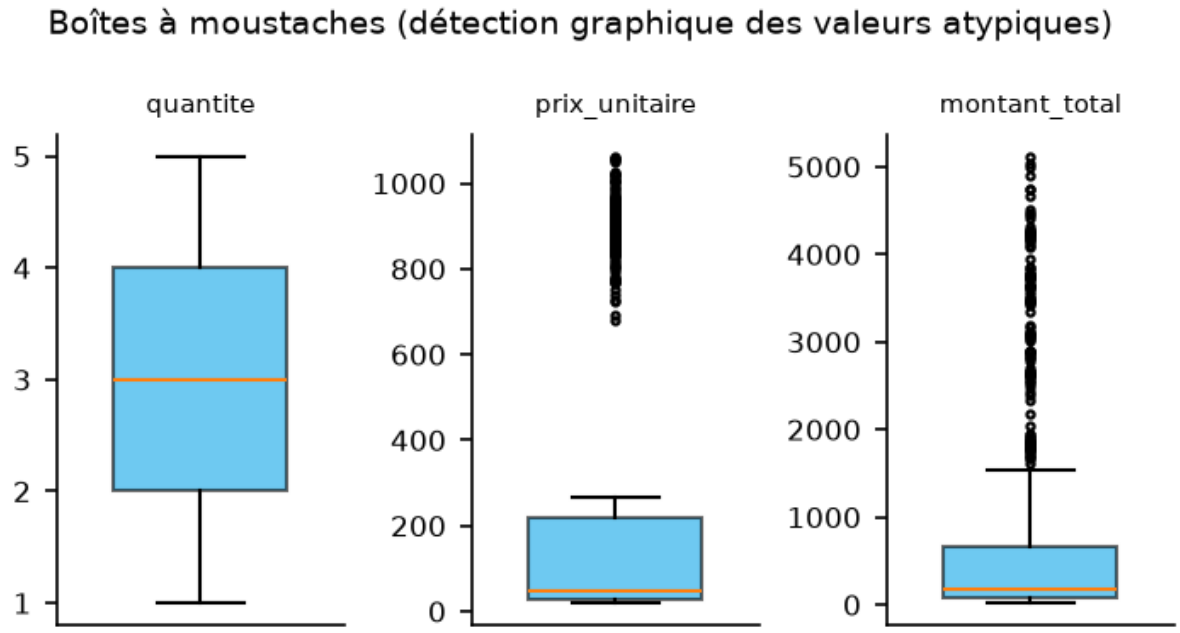
Problèmes détectés

Contrôle	Variable	Sévérité	Nombre	Constat
Valeurs manquantes	commentaire	critique	537	53.7 % de valeurs manquantes.
Valeurs atypiques potentielles	prix_unitaire	majeur	152	152 valeur(s) hors de [-261.6 ; 509.1] (IQR × 1.5), dont 0 également avec |z| > 3.
Valeurs atypiques potentielles	montant_total	majeur	120	120 valeur(s) hors de [-782 ; 1536] (IQR × 1.5), dont 38 également avec |z| > 3.
Type de données incorrect	date_commande	info	1000	Dates stockées sous forme de texte (format %Y-%m-%d).

Valeurs atypiques (IQR et z-score)

Les valeurs atypiques ne sont pas nécessairement des erreurs : elles peuvent refléter un phénomène réel ou une sous-population.

Variable	n	Borne basse (IQR)	Borne haute (IQR)	Atypiques IQR	% IQR	Atypiques |z|>3	Signalées par les deux
quantite	1000	-1	7	0	0	0	0
prix_unitaire	1000	-261,65	509,15	152	15,2	0	0
montant_total	1000	-782,0487	1 535,8612	120	12	38	38

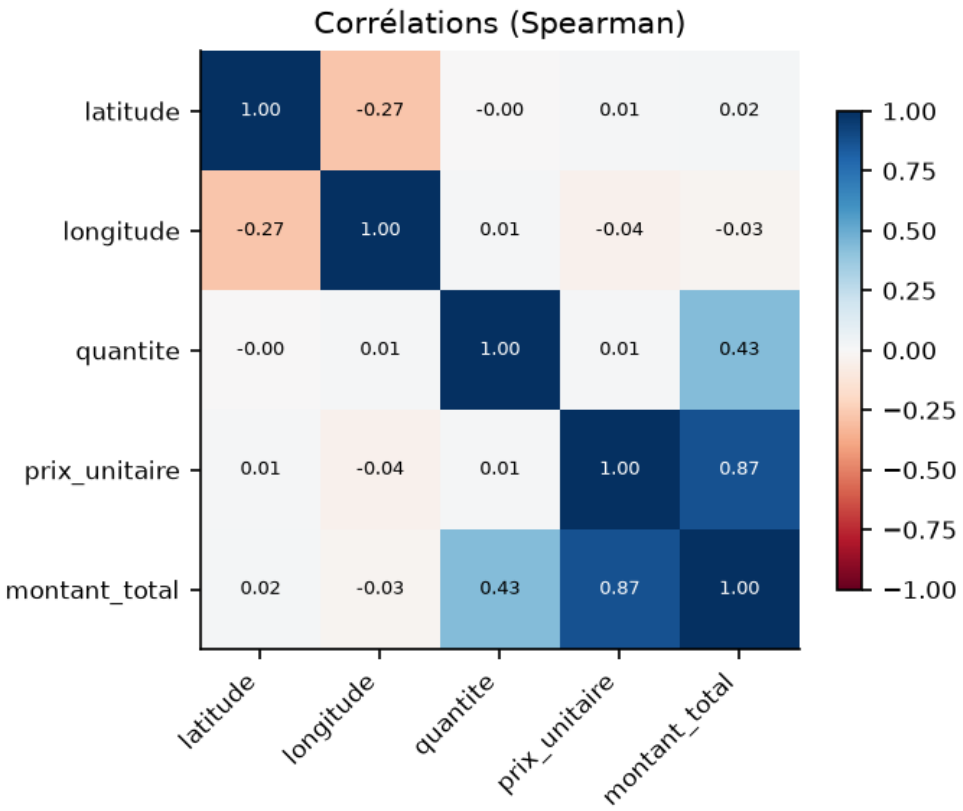


7. Analyse des corrélations

Méthode retenue : Spearman. 2 variable(s) fortement asymétrique(s) et 2 avec des valeurs extrêmes : Spearman (sur les rangs) est plus robuste que Pearson.

Conditions d'utilisation : Aucune hypothèse de normalité ; robuste aux valeurs aberrantes ; adapté aux variables ordinales ou aux relations non linéaires monotones.

Les valeurs manquantes sont exclues paire par paire ; l'effectif utilisé (n) est indiqué pour chaque paire. Corrélation n'implique pas causalité.



Principales paires

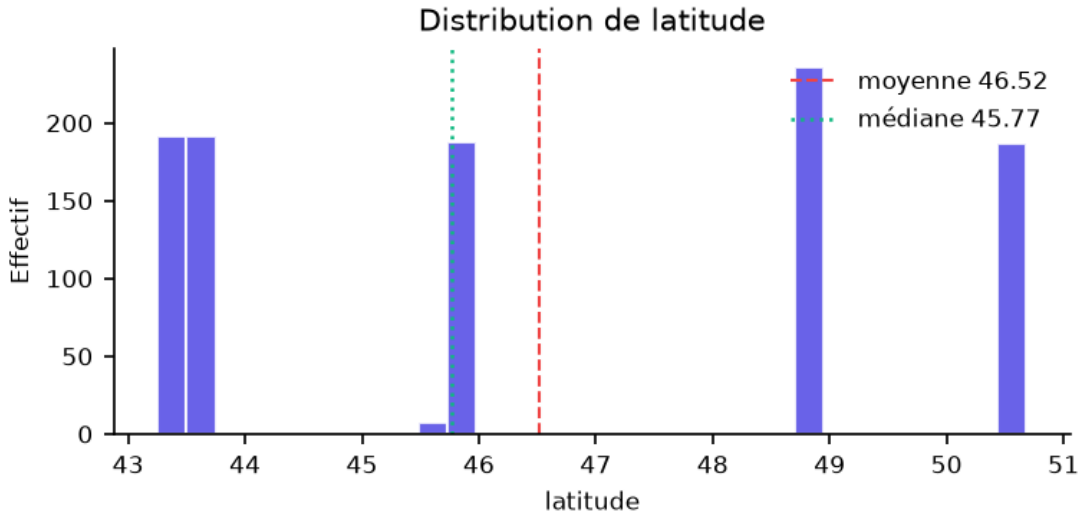
Variable 1	Variable 2	Coefficient	|r|	Intensité	Sens	p-value	n
prix_unitaire	montant_total	0,8702	0,8702	forte	positive	5,422e-309	1000
quantite	montant_total	0,4347	0,4347	modérée	positive	2,32e-47	1000
latitude	longitude	-0,2744	0,2744	faible	négative	9,812e-19	1000
longitude	prix_unitaire	-0,0404	0,0404	négligeable	négative	0,2015	1000
longitude	montant_total	-0,029	0,029	négligeable	négative	0,3596	1000
latitude	montant_total	0,0175	0,0175	négligeable	positive	0,5811	1000
latitude	prix_unitaire	0,0125	0,0125	négligeable	positive	0,693	1000
quantite	prix_unitaire	0,0099	0,0099	négligeable	positive	0,7555	1000
longitude	quantite	0,009	0,009	négligeable	positive	0,7764	1000
latitude	quantite	-0,0024	0,0024	négligeable	négative	0,9386	1000

Fortes associations (toutes mesures)

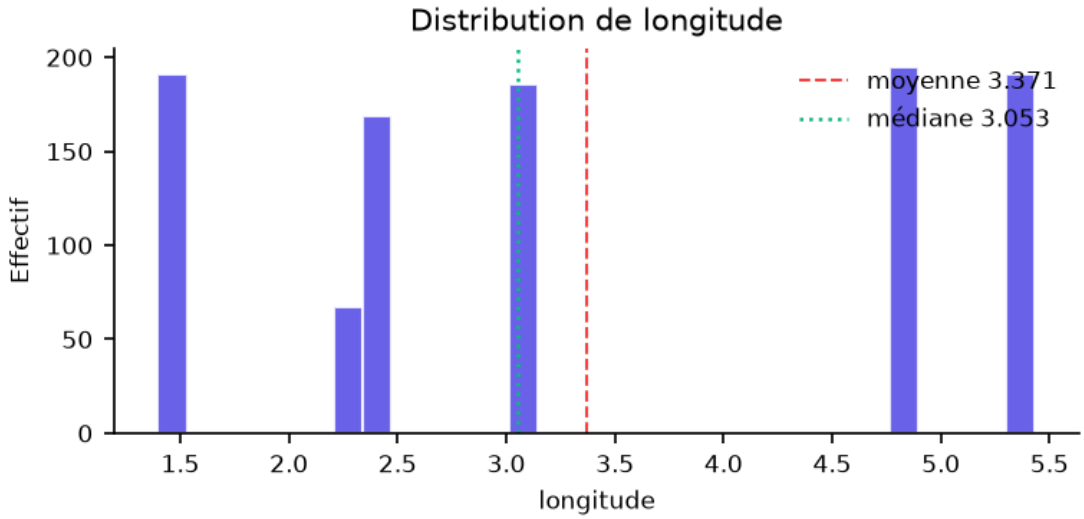
Variable 1	Variable 2	Mesure	Valeur	Intensité
prix_unitaire	montant_total	Corrélation (Spearman)	0,8702	forte
latitude	ville	η^2 (rapport de corrélation)	1	forte
longitude	ville	η^2 (rapport de corrélation)	0,9998	forte
prix_unitaire	produit	η^2 (rapport de corrélation)	0,9901	forte
montant_total	produit	η^2 (rapport de corrélation)	0,7641	forte

8. Visualisations principales

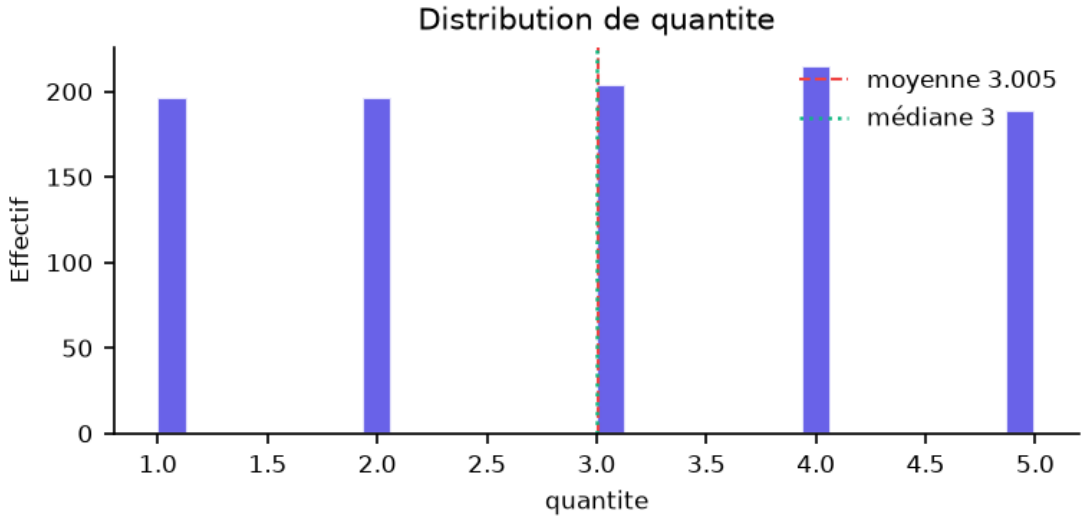
Distribution de latitude



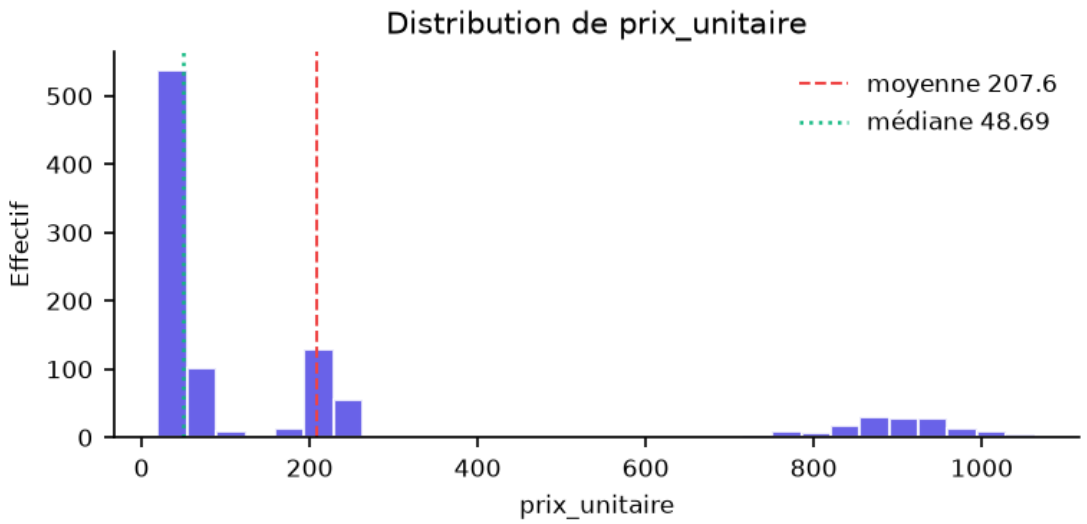
Distribution de longitude



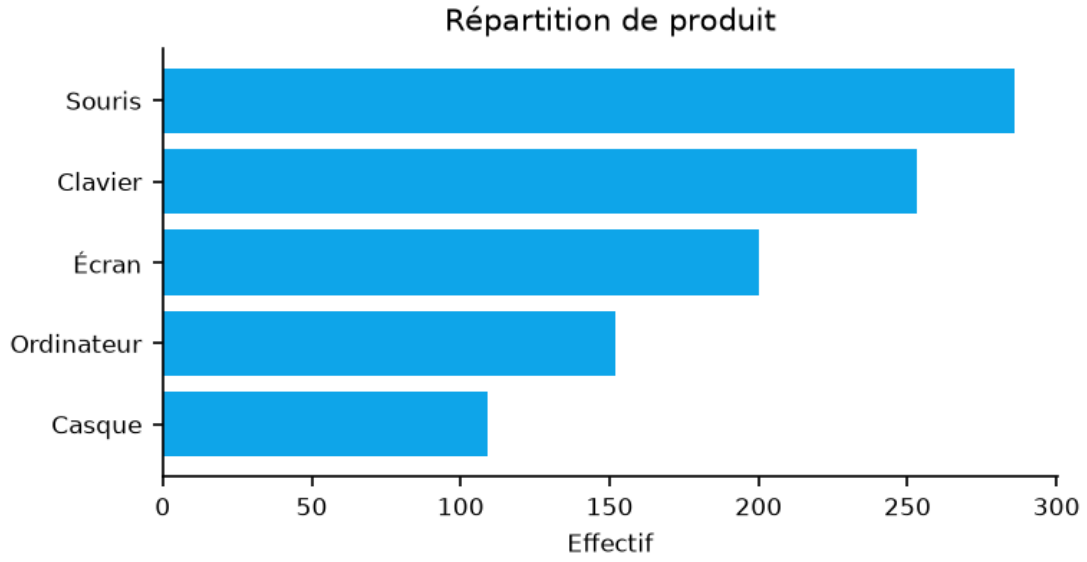
Distribution de quantite



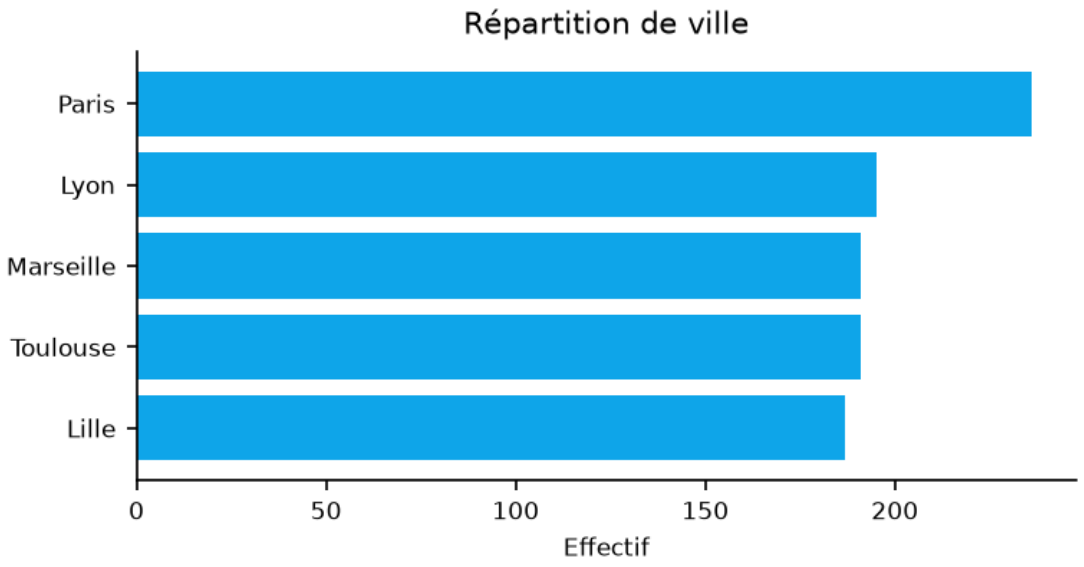
Distribution de prix_unitaire



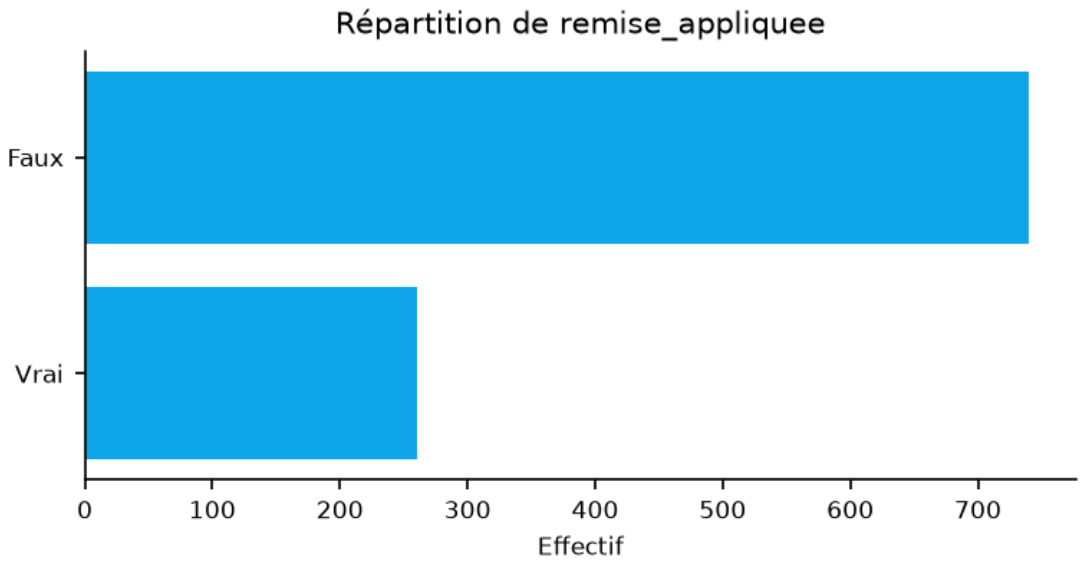
Répartition de produit



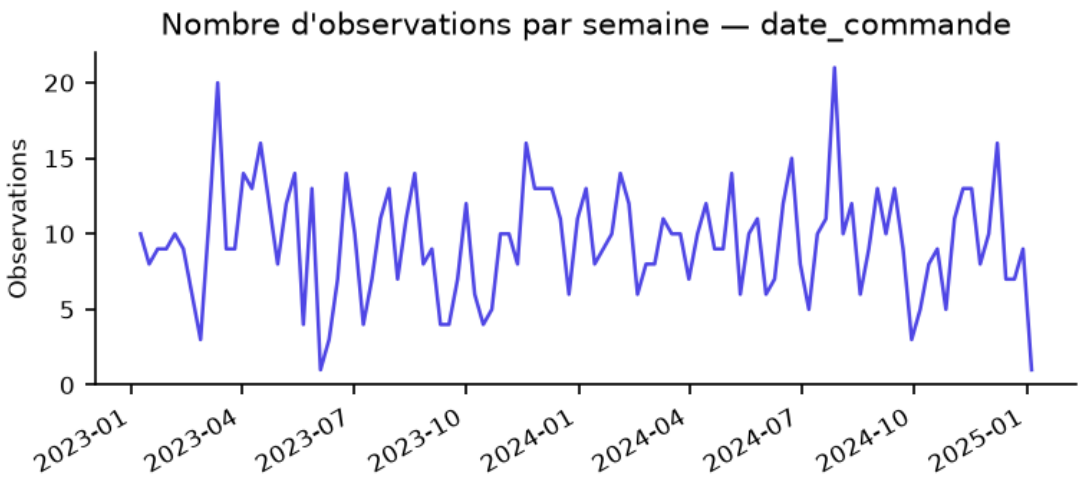
Répartition de ville



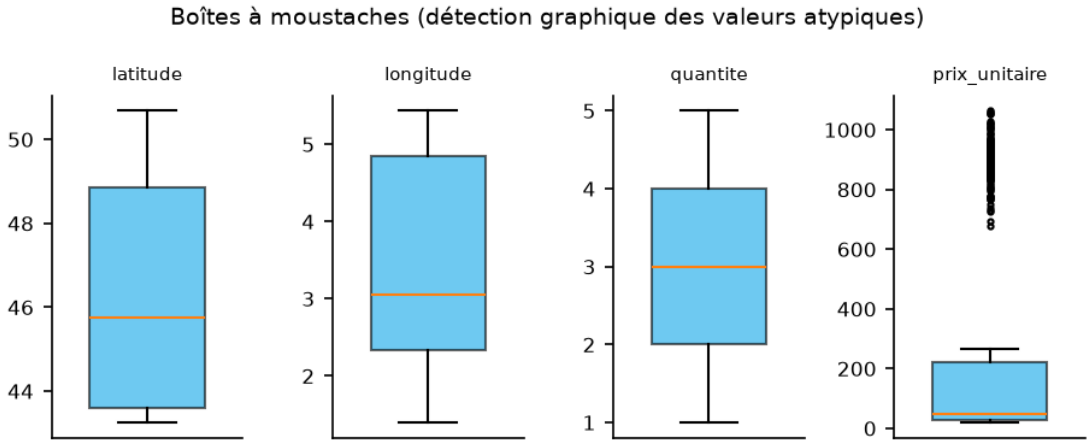
Répartition de remise_appliquee



Évolution temporelle de date_commande



Boîtes à moustaches



9. Interprétations statistiques

Les commentaires sont générés par des règles appliquées aux résultats calculés. Ils distinguent les constats (faits chiffrés), les interprétations, les hypothèses (à vérifier) et les recommandations.

Constats

- « prix_unitaire » présente une forte dispersion : coefficient de variation de 145,6 % (écart-type 302,34 pour une moyenne de 207,62).
- Distribution de « prix_unitaire » asymétrique à droite (queue vers les grandes valeurs) : skewness = 1,77.
- « montant_total » présente une forte dispersion : coefficient de variation de 165,3 % (écart-type 1 030,40 pour une moyenne de 623,25).
- Distribution de « montant_total » asymétrique à droite (queue vers les grandes valeurs) : skewness = 2,45.
- « commentaire » est très incomplète : 53,7 % de valeurs manquantes.
- Corrélation forte et positive entre « prix_unitaire » et « montant_total » (Spearman r = 0,870, n = 1000).
- « date_commande » couvre du 04/01/2023 au 30/12/2024 (726 jours), fréquence estimée : journalière.
- « date_commande » : 134 interruption(s) : écart supérieur à 1,5 × l'écart médian (1.00 j).
- « date_commande » : 24.8 % des écarts s'éloignent de la fréquence journalière.
- « prix_unitaire » : 152 valeurs atypiques selon la règle IQR (15,2 %).
- « montant_total » : 120 valeurs atypiques selon la règle IQR (12,0 %).
- « Faux » est majoritaire dans « remise_appliquee » (74,0 %).

Interprétations

- La moyenne de « prix_unitaire » résume mal les observations ; la médiane (48,69) et l'écart interquartile sont plus représentatifs.
- La moyenne de « montant_total » résume mal les observations ; la médiane (176,39) et l'écart interquartile sont plus représentatifs.
- « montant_total » a des queues épaisses (excès d'aplatissement 5,27) : les valeurs extrêmes sont plus fréquentes que pour une loi normale.
- Une corrélation mesure une association, pas une causalité : un facteur commun ou une relation mathématique (ex. total = prix × quantité) peut l'expliquer.

- Les tests de normalité (Shapiro-Wilk ou D'Agostino, α = 0.05) rejettent l'hypothèse de normalité pour 5 variable(s) : latitude, longitude, quantite, prix_unitaire, montant_total. Privilégier des méthodes non paramétriques (médiane, Spearman, Kruskal-Wallis) pour ces variables.

Hypothèses

- Les 134 interruption(s) de « date_commande » peuvent refléter des périodes sans activité (week-ends, fermetures) ou des données non collectées.
- Les manquants de « commentaire » peuvent ne pas être aléatoires (question facultative, information non applicable) : vérifier avant toute imputation.
- Des variables très corrélées peuvent porter une information redondante.

10. Recommandations

- Valeurs manquantes — commentaire : Supprimer la colonne (> 50 %) ou imputer (médiane pour le numérique, mode pour le catégoriel) après analyse du mécanisme de non-réponse.
- Valeurs atypiques potentielles — prix_unitaire : Vérifier ces valeurs : une valeur atypique n'est pas nécessairement une erreur (phénomène réel, sous-population). Corriger les erreurs avérées ; sinon envisager une transformation (log) ou des méthodes robustes.
- Valeurs atypiques potentielles — montant_total : Vérifier ces valeurs : une valeur atypique n'est pas nécessairement une erreur (phénomène réel, sous-population). Corriger les erreurs avérées ; sinon envisager une transformation (log) ou des méthodes robustes.
- Envisager une transformation logarithmique de « prix_unitaire » (valeurs strictement positives) avant des méthodes supposant la normalité.
- Envisager une transformation logarithmique de « montant_total » (valeurs strictement positives) avant des méthodes supposant la normalité.